

Downscaling Campos de Viento

Asael Acosta
asael906@mit.edu

Julio 2025

Resumen

Downscaling es el uso de métodos dinámicos o estadísticos para aumentar la resolución de datos gruesos. Actualmente, métodos numéricos son los más comunes en lograr downscaling, pero tienen la desventaja de tomar bastante tiempo. De igual forma a GenCast, hay modelos IA que existen justamente para acelerar el proceso de downscaling. Aquí presento información contextual de downscaling, ejemplos de su uso, mis recomendaciones y referencias útiles.

1. Introducción

En términos generales, hacer downscaling es usar información de baja resolución y conocimiento secundario para inferir información de alta resolución. Un ejemplo de esto se mira en figura 1, en donde se usa climatología local para aumentar la resolución de una imagen grabada por un satélite. La utilidad de downscaling es que puedes sacar mucha información de datos gruesos si tienes un conocimiento contextual y evita la necesidad de tener acceso a datos de alta resolución desde el inicio. En el caso de nosotros, usaremos downscaling para mejorar la resolución de campos de viento que genera GenCast.

Hay dos marcos para cumplir downscaling, métodos dinámicos y métodos estadísticos [10]. Brevemente, downscaling dinámico usa datos gruesos como condiciones iniciales para correr un modelo climatológico sobre una región relativamente pequeña (entre 10 y 50 km²). Este método tiene la ventaja de sacar resultados bien detallados y con alta precisión, pero toma bastante tiempo. Los métodos estadísticos, en contraste, buscan relaciones entre datos gruesos y finos conocidos. Usan esas relaciones para inferir como se deben ver datos de alta resolución para nuevos datos gruesos. Esta forma de hacer downscaling tiene la ventaja de ser más rápido, pero opera bajo ciertas suposiciones que no siempre aplican. A pesar de eso, el uso de métodos estadísticos bajo la IA puede ser útil en evitar aquellos problemas y aún sacar datos finos y precisos [3, 4, 5, 8, 10].




Figura 1: Un ejemplo de downscaling en Alaska tomado de [1]. Los puros datos climáticos son gruesos y no contienen mucha información útil. Sin embargo, se puede usar el conocimiento de topografía, física, etc para inferir datos mucho más finos.

2. Retos y Soluciones

Lo que hace modelos de IA tan útiles para implementar downscaling estadístico es el hecho de que IA es muy bueno para sacar patrones cuando esté entrenado usando datos de buena calidad. Esto es más o menos conocimiento común, pero sí hay ciertas desventajas de IA que necesitamos tomar en cuenta si lo usamos. Un ejemplo es overfitting, que es el producto de entrenamiento exagerado. En vez de sacar patrones a través de su entrenamiento, el modelo simplemente memoriza los datos y no generaliza bien cuando procesa datos desconocidos [6]. En esa misma referencia puedes encontrar más información detallado acerca de modelos de IA, y puedes aprender sobre sus debilidades generales en los primeros capítulos. De hecho, recomiendo que lo uses como referencia para entender que está pasando mecánicamente en el modelo que usarás. Sin embargo, no contiene mucha información de como programar un modelo IA, entonces no me preocuparía por leerlo todo.

2.1. PINN

Una debilidad que quiero enfocarme en específico es el hecho de que modelos de IA normalmente se entrenan con puros datos y sin guía fuera de eso. En muchos casos, eso no es problemático porque las propiedades latentes de los datos de entrenamiento se pueden inferir sin problema por el modelo. A pesar de eso, no siempre hay acceso a datos completos o quizás solo tiene acceso a datos que no representan muy bien los casos generales. Además, datos pueden ser imperfectos y contener información que viola ciertos principios de la ciencia, matemática, etc. Por ejemplo, imagina un red neuronal que está entrenado para predecir la altura de un globo que alguien soltó, después de cierto tiempo.

Suponga que en los datos de entrenamiento, solo hay datos de la posición del globo cuando está subiendo. La conclusión natural de los datos sería que la posición del globo sigue incrementando linealmente sin parar. En realidad, el globo sube hasta que la presión dentro del globo iguala a la presión de la atmósfera. Después se queda en equilibrio y baja mientras que no salga el helio.

Con eso en mente, cómo se enseña al modelo este fenómeno sin que hayan datos mostrándolo? Una manera útil de cumplir esto es modificar la función de pérdida del modelo para que la física sea parte de ella y el modelo aprende a sacar patrones que se alinean con los datos de entrenamiento y a la vez con la física gobernando la posición del globo [2, 7]. Se puede ver este beneficio en el ejemplo simple de figura 2. Hay más información de funciones de pérdida en [6] dentro de capítulos dos (más breve) y cinco (más profundo).

Un red neuronal implementación de física como función de pérdida se llama un *Physics Informed Neural Network (PINN)* y figura 3 ejemplifica uno que usa una de las ecuaciones Navier Stokes como la función de pérdida secundaria. La manera más simple de usar la física para alimentar el entreno de los modelos es simplemente añadir las dos funciones.

$$L_{total}(\phi) = L_{datos}(\phi) + L_{física}(\phi) \quad (1)$$

Donde L denota una función de perdida, los subíndices denotan de donde viene la pérdida, y ϕ denota un vector que contiene los parámetros del red neuronal. En este ejemplo, los parámetros son los pendientes de la función antes y después de t_0 . Más información de que significan los parámetros se encuentra en los primeros dos capítulos de [6]. Pon atención al hecho de que las dos funciones de pérdida tienen el mismo peso. Es decir, los dos tiene el mismo magnitud de impacto en la pérdida total. Si quisiera asegurarse que el modelo enfatizaría alineamiento, podría escalar L_{datos} , $L_{física}$ por constantes a, b respectivamente.

2.2. Usando PINN

PINN, a pesar de ser una técnica relativamente nuevo, ha sido usado por varios académicos para hacer downscaling en campos de precipitación bajo condiciones extremos [8]. Ese mismo artículo, escrito por Sai Ravela, usa variables climáticos (e.g. viento, presión, orografía) encima de los datos gruesos de entrada para mejor inferir cuales regiones tendrían más precipitación que otras. Sí logra buenísimos resultados porque pudo convertir datos de ERA5, los cuales tiene una resolución de 0.25° por latitud y longitud, a datos de 0.01° de resolución. El proceso entero de como hace downscaling el modelo y como se entrena está en 4. Brevemente, se usa dos diferentes GANs [9] para cumplir downscaling dos veces. En la primera instancia de downscaling, se procesan los datos gruesos de ERA5 que queremos downscale, los cuales tienen una resolución de 0.25° , otros datos climáticos de ERA5 que no se modificarán, y datos especificando la elevación del terreno. Estos datos alimentan al primer GAN que sube la resolución a 0.1° . Estos nuevamente procesados datos después se meten al segundo GAN para subir la resolución de nuevo a 0.01° . La razón por usar dos diferentes modelos de




Figura 2: Tomando en mente que una red neuronal se puede tratar como una ecuación matemática [6], miramos el ejemplo simple de una red con parámetros ϕ . t_0 significa el tiempo que ha pasado para que el globo alcance una altura donde ya no sube más. En el caso izquierdo, no hay cualquier pérdida asociada con la física, entonces el globo supuestamente seguirá subiendo sin parar. Por el lado derecho, vemos un ejemplo de un modelo que entiende, por causa de su pérdida física, que el globo se quedará en la misma altura después de t_0 .




Figura 3: Un ejemplo de un PINN tomado de [2]. La física usado aquí viene de una de las ecuaciones Navier Stokes, los cuales gobiernan el comportamiento de fluidos. Las azules entradas del red son variables denotando posición espacio-temporal. Las rojas salidas son los tres componentes del vector de velocidad y la nivel de presión en ese fluido. Los elementos morados son las cantidades que se computarán usando las salidas. Usando esos elementos, puede ver que tanto o poco se satisface la física. Las diferencias entre lo que calcula el red y lo que esperamos según la física son sumados para obtener la pérdida física ("virtual." en la foto). La diferencia entre la salida del red y la verdad según los datos de entrenamiento es la pérdida de los datos ("data." en la foto).

downscaling es necesario porque los datos usados para entrenar los dos GANs vienen de diferentes fuentes y tienen diferentes sesgos en ellos mismos. El efecto de los sesgos en el entrenamiento se mitiga y es más fácil para corregir si se separan los pasos del downscaling como lo hizo Sai Ravela.

Encima de su visualización en figura 4, se puede encontrar un breve resumen del proceso en cuatro puntos en página dos de [8]. Enfatizo que cada uno de los GANs tiene un elemento físico informando sus salidas. En el primer GAN, una de las entradas es el Upslope Model, lo cual captura la estructura del terreno y como influencia la distribución de lluvia. Por eso no entran directamente los variables climáticos ni los datos de elevación al modelo. Si se usan para crear un modelo de los efectos del terreno a la precipitación, la IA aprende justamente el efecto topográfico en la lluvia. Esto tiene el beneficio de entrenar el modelo con más precisión.

La única razón por lo cual este modelo no es mi primera recomendación es que el código no tiene documentación que aclara como se puede modificar o adaptar para usos como el de nosotros. Por ejemplo, la IA requiere un Upslope Model para cumplir el primer paso de downscaling. Se necesita programar un Upslope Model justamente para viento si quiere usar este IA. No obstante, cuando tenga más conocimiento de la construcción de pipelines de IA por haber trabajado con otro modelo, recomendaría que busca como se puede usar este modelo. De hecho, incluyendo un elemento constreñido [2.3] en conjunción con el resto de las características físicas de este modelo será útil. Cuando llegues a trabajar con este modelo, recomiendo que se reúna con Sai Ravela para mejor entender la adaptación de su modelo para uso en campos de viento.

2.3. Aprendizaje Constreñido

Aunque el uso de física a través de una función de pérdida pueda mejorar los resultados de un red neuronal, no garantiza que los datos finos corresponden exactamente a los datos gruesos. Es decir, si uno hace afina un grupo de datos, debe de ser posible engrosar los datos nuevos para recrear los datos iniciales (mira figura 5). Es posible meter un término a la función de pérdida que tiene que ver con la correspondencia entre los datos finos y gruesos, algo que ya sabemos logra buenos resultados en los PINNs. Este entrenamiento que exactamente respeta los datos originales es un ejemplo de aprendizaje constreñido [3].

Lo bueno de esta manera de entrenar el modelo es que encima de sacar resultados físicamente plausible, apoya el aprendizaje del modelo para ser más eficiente. Si el modelo solamente genera resultados relacionados con los datos gruesos, no está gastando recursos o tiempo midiendo salidas. Es decir, el entrenamiento será más eficaz.

3. Conclusión

Últimamente, el problema de crear versiones afinadas de datos predijendo el tiempo nos permite acceso a soluciones únicas. Primariamente, miramos




Figura 4: Tomada de [8]




Figura 5: Visualización del proceso de afinar y luego engrosar datos. En un caso ideal, los datos engrosados de los afinados son idénticos a los datos originales.

que modelos de IA pueden ser optimizados o entrenados justamente para este propósito, con las restricciones impuestos por la física para imponer resultados razonables del mismo modelo. Si sea necesario aclarar algún información, me puede alcanzar por el correo electrónico al en la cima de este documento.

Referencias

- [1] University of Alaska Fairbanks. 2025. URL: <https://uaf-snap.org/how-do-we-do-it/downscaling/> (visitado 31-07-2025).
- [2] Steve Brunton. *Physics Informed Neural Networks (PINNs) [Physics Informed Machine Learning]*. <https://www.youtube.com/watch?v=-zrY7P2dVC4>. [Online; accessed 01-August-2025]. 2024.
- [3] Paula Harder et al. *Generating physically-consistent high-resolution climate data with hard-constrained neural networks*. 2022. URL: <https://github.com/RolnickLab/constrained-downscaling>.
- [4] Fabio Merizzi, Andrea Asperti y Stefano Colamonaco. «Wind speed super-resolution and validation: from ERA5 to CERRA via diffusion models». En: *Neural Computing and Applications* (2024). URL: <https://github.com/fmerizzi/ERA5-to-CERRA-via-Diffusion-Models>.
- [5] Ophélie Miralles et al. «Downscaling of Historical Wind Fields over Switzerland Using Generative Adversarial Networks». En: *American Meteorological Society* (2022).
- [6] Simon J.D. Prince. *Understanding Deep Learning*. The MIT Press, 2023. URL: <http://udlbook.com>.
- [7] M. Raissi, P. Perdikaris y G.E. Karniadakis. «Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations». En: *Journal of Computational Physics* 378 (2019), págs. 686-707. ISSN: 0021-9991. DOI: <https://doi.org/10.1016/j.jcp.2018.10.045>. URL: <https://www.sciencedirect.com/science/article/pii/S0021999118307125>.
- [8] Ravela Sai y Anamitra Saha. «Statistical-Physical Adversarial Learning from Data and Models for Extreme Rainfall Downscaling». En: *Journal of Advances in Modeling Earth Systems* (2024). <https://arxiv.org/pdf/2212.01446>. URL: <https://zenodo.org/records/7900921>.
- [9] Jordi de la Torre. «REDES GENERATIVAS ADVERSARIAS (GAN) FUNDAMENTOS TEÓRICOS Y APLICACIONES». En: *arXiv* (2023). URL: <https://arxiv.org/pdf/2302.09346>.
- [10] Robbie A. Watt y Laura A. Mansfield. *Generative Diffusion-based Downscaling for Climate*. 2024. arXiv: [2404.17752](https://arxiv.org/abs/2404.17752) [[physics.ao-ph](https://arxiv.org/abs/2404.17752)].